Housing Price Prediction

28/09/2026

# Báo cáo tiến độ

# Sprint 1

Dự đoán giá căn hộ chung cư Việt Nam — Giai đoạn thu thập và làm sạch dữ liệu



Thời lượng trình bày: ~10 phút

TỔNG QUAN SPRINT

# Hoàn thành giai đoạn dữ liệu, sẵn sàng xây mô hình

**20.290**
tin đăng thu thập từ 3 nguồn

**15.899**
dòng sạch, sẵn sàng huấn luyện

**0 / 12.045**
tin lệch giá khi đối chiếu với site

**100%**
ghép được dữ liệu kinh tế – xã hội

## Tiến độ theo kế hoạch 5 tuần

**Tuần 1–2** — Hoàn thành
Thu thập & làm sạch dữ liệu

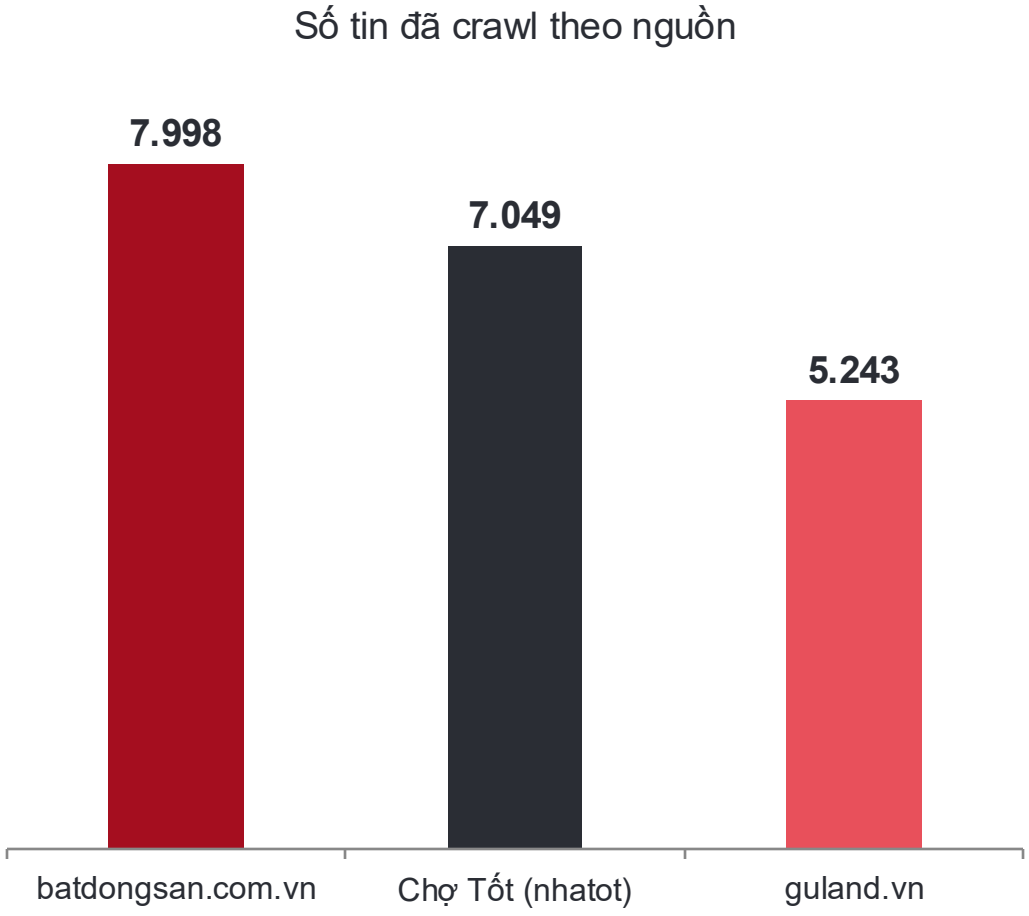
**Tuần 3** — Tiếp theo
Kiểm tra tự động, chia dữ liệu, baseline

**Tuần 4** — Kế hoạch
EDA, feature, mô hình, ablation

**Tuần 5** — Kế hoạch
Giải thích mô hình (SHAP), báo cáo cuối

THU THẬP DỮ LIỆU

# 20.290 tin đăng căn hộ từ 3 nguồn độc lập




1

## batdongsan.com.vn

Trình duyệt tự động vượt Cloudflare. Tối ưu tốc độ 30 → 6,5 giây/tin bằng chặn ảnh, quảng cáo và khởi động lại trình duyệt định kỳ.

2

## Chợ Tốt

API JSON công khai — lấy gần toàn bộ ~7.000 tin bán đang hiển thị, có tọa độ và ngày đăng chính xác.

3

## guland.vn

HTTP giả lập dấu vân tay trình duyệt để qua Cloudflare. Bổ sung Hà Nội và các tỉnh nhỏ.

TRƯỜNG DỮ LIỆU THU THẬP

# Mỗi nguồn 36–40 trường, độ đầy đủ không đều

| Nhóm trường | batdongsan 7.998 tin | Chợ Tốt 7.049 tin | guland 5.243 tin |
|---|---|---|---|
| Giá, diện tích, giá/m² | 99% | 98% | 99% |
| Số phòng ngủ | 93% | 98% | 41% |
| Số WC | 90% | 81% | 36% |
| Tọa độ | 99% | 99% | 8% |
| Tỉnh / quận / phường | 99% | 99% | 60% |
| Tên dự án | 96% | 68% | 41% |
| Giấy tờ pháp lý | 84% | 76% | 28% |
| Nội thất | 75% | 68% | — |
| Hướng ban công | 44% | 29% | 19% |
| Tầng, căn góc, block | — | 23% | — |
| Chủ đầu tư, số tòa, số căn | 96% | — | — |
| Người đăng, ngày đăng, mô tả | 99% | 99% | 99% |

*% tin có giá trị trong dữ liệu thô · — : nguồn không cung cấp trường này*

## Nhận định

- Chợ Tốt đầy đủ nhất về căn hộ: phòng, tọa độ, tầng, căn góc.
- batdongsan mạnh về dự án: chủ đầu tư, số tòa, số căn.
- guland chỉ 8% có tọa độ, 41% có số phòng ngủ; sau bổ sung tọa độ theo dự án tăng lên 39%.
- Rủi ro: mô hình học "thiếu dữ liệu = tin guland" — đã đưa vào quy tắc tạo feature để kiểm soát.

CẤU TRÚC BỘ DỮ LIỆU SAU LÀM SẠCH

# 21.015 dòng × 99 cột: 52 cột gốc, 47 cột tạo mới




## 52 cột

### Giữ nguyên từ crawl

Văn bản gốc (title, mô tả, giá, địa chỉ) để truy vết và kiểm tra lại mọi quyết định làm sạch.

## 6 cột

### Số liệu đã đọc chuẩn

price, area, price_per_m2, bedrooms, bathrooms — nhãn dự đoán là giá/m².

## 12 cột

### Vị trí chuẩn hóa

Tỉnh, quận cũ; tỉnh, phường mới 2025; vùng thị trường; cờ kiểm tra tọa độ.

## 10 cột

### Phân loại căn hộ

Loại tin, loại căn (studio, duplex…), sở hữu, công năng, pháp lý, phân khúc giá.

## 7 cột

### Cờ chất lượng

Dùng được làm nhãn không, lý do loại, giá tối thiểu, giá ước lượng, giá bất thường.

## 4 cột

### Khử trùng lặp

Trùng chắc chắn, bản gốc, quy tắc trùng, nhóm có thể trùng.

## 8 cột

### Dữ liệu bổ trợ

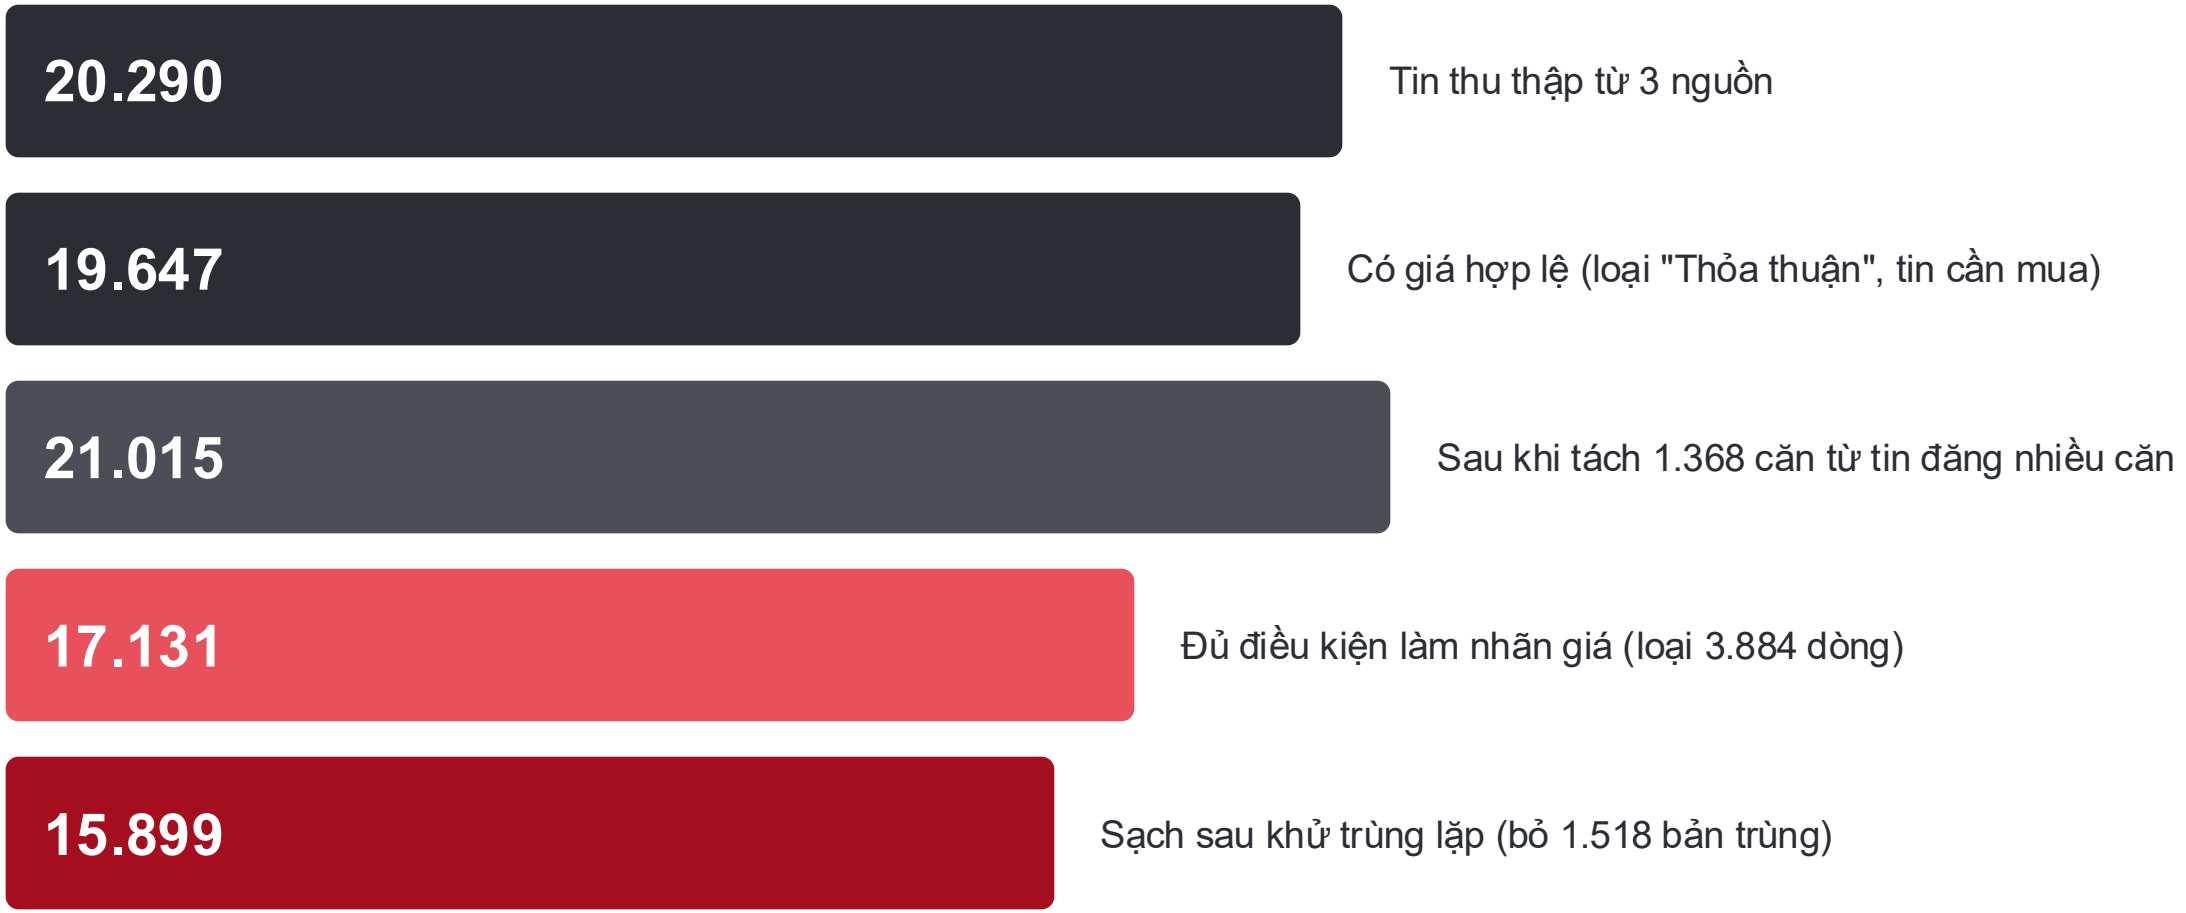
Dân số, mật độ, GRDP/người của tỉnh; trạng thái, chủ đầu tư, quy mô dự án.

### Không xóa dòng nào

Mọi dòng loại đều giữ cờ và lý do; 15.899 dòng sạch được lọc bằng 2 cột: is_trainable và is_duplicate_fuzzy.

QUY TRÌNH LÀM SẠCH

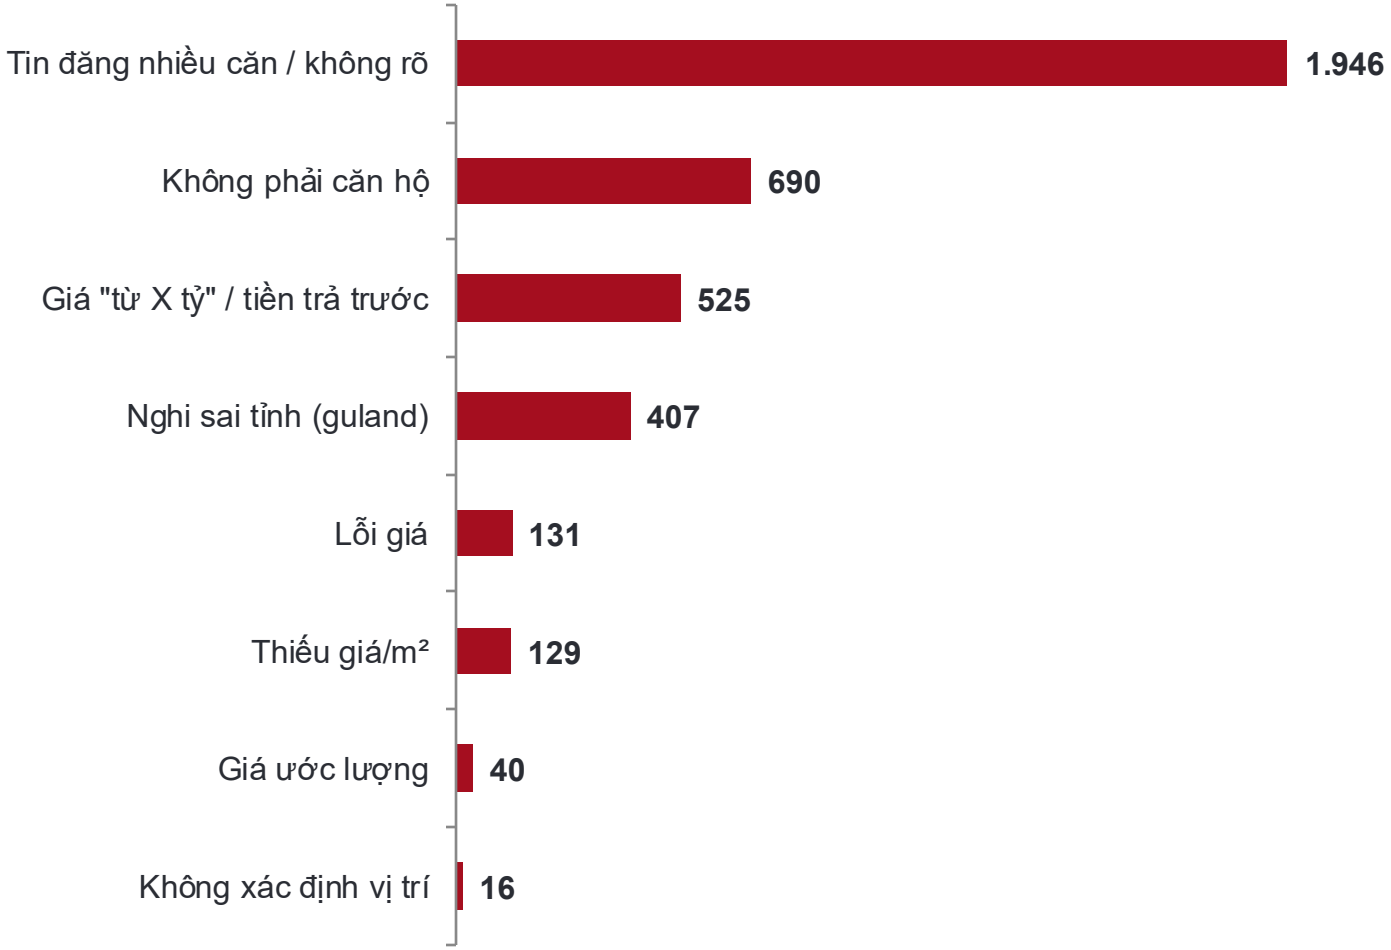
# Từ 20.290 tin thô đến 15.899 dòng sạch




*Dữ liệu được đóng băng thành phiên bản v2 (mã hash từng file) — mọi thí nghiệm sau này dùng đúng một bộ dữ liệu, kết quả so sánh được với nhau.*

LÝ DO LOẠI DỮ LIỆU

# 3.884 dòng bị loại, mỗi dòng có lý do




## Nguyên tắc

- Không xóa cứng dòng nào — mỗi dòng giữ cờ và lý do loại để kiểm tra lại.
- Giá cao hợp lý (penthouse, hàng hiệu) được GIỮ; chỉ loại giá không thể có thật (<10 hoặc >3.000 tr/m²).
- Tin nghi sai tỉnh được giữ lại để đo ảnh hưởng ở bước so sánh mô hình.

PHÁT HIỆN CHÍNH (1/2)

# Ba lỗi dữ liệu "âm thầm" đã phát hiện và xử lý

## 1 Giá bị đọc sai 100 lần

guland viết "4.35 tỷ", batdongsan viết "4,05 tỷ". Đọc theo một quy ước duy nhất biến 4,35 tỷ thành 435 tỷ.

**Xử lý**

Đọc số theo quy ước từng nguồn

**5.243 tin guland**

## 2 Tọa độ mặc định

Khi người đăng không ghim, site tự điền điểm cố định (guland: Tân Bình; batdongsan: Hồ Gươm, Ba Đình). Căn ở Hà Nội bị đặt lệch ~1.100 km.

**Xử lý**

Chỉ nhận ghim thật; điểm xuất hiện ở ≥2 quận bị xóa; mượn tọa độ theo dự án

**1.725 tin được bù tọa độ**

## 3 guland gán sai tỉnh

Gán tỉnh bằng khớp tên: đường "Điện Biên Phủ" thành tỉnh Điện Biên. Tin "Điện Biên" thực tế ở Đà Nẵng, Hà Nội, Quy Nhơn.

**Xử lý**

Đánh dấu nghi sai tỉnh, loại khỏi tập huấn luyện

**407 tin**

PHÁT HIỆN CHÍNH (2/2)

# Loại bỏ những tin không phản ánh giá của một căn hộ

**1.417 tin** — **Tin đăng nhiều căn**

Một bài rao cả "rổ hàng": giá và diện tích hiển thị không cùng một căn. Tách được 1.368 căn bằng cách ghép đúng 1 diện tích – 1 giá; đọc được giá kiểu môi giới "2 tỷ3" = 2,3 tỷ.

**690 tin** — **Không phải căn hộ**

391 cả tòa nhà cho thuê, sàn văn phòng, shophouse; 290 nhà riêng và đất; 9 căn trong rổ hàng là nhà phố. Giá 150–1.000 tr/m² làm lệch mô hình nếu giữ lại.

**696 tin** — **Giá không phải giá bán**

525 giá "từ X tỷ" hoặc tiền trả trước ("vốn 1 tỷ"); 131 lỗi giá; 40 giá ước lượng ("gần 2 tỷ").

**53 + 47** — **Dữ liệu trình bày bất thường**

53 tiêu đề viết bằng chữ trang trí Unicode qua mặt mọi luật từ khóa; 47 quận có ≥2 cách viết giữa các nguồn — đã chuẩn hóa.

KHỬ TRÙNG LẶP

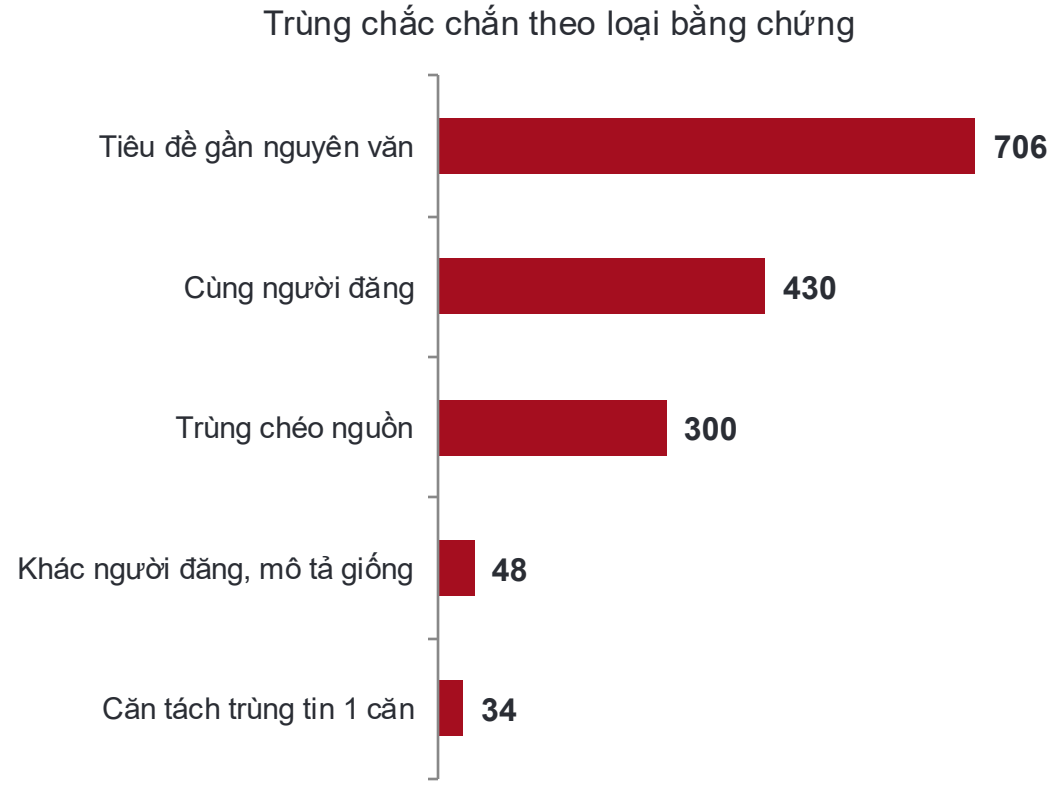
# Xử lý trùng lặp theo hai tầng, tránh điểm số "đẹp giả"

## Trùng chắc chắn — 1.518 dòng

Có bằng chứng: mô tả chép lại, cùng người đăng, trùng chéo nguồn với giá lệch ≤1%. Giữ 1 bản tốt nhất mỗi cụm, bỏ phần còn lại khi huấn luyện.

## Có thể trùng — 2.292 nhóm

Cùng dự án – diện tích – giá nhưng không đủ bằng chứng. Không loại, chỉ gom vào cùng một phía khi chia train/test. Nhóm lớn nhất 46 tin (0,2%).




*Đã sửa lỗi nối nhầm khiến một nhóm trùng phình tới 183 tin ở 9 tỉnh; mọi liên kết trùng được lưu lại để kiểm tra.*

CHUẨN HÓA HÀNH CHÍNH & DỮ LIỆU BỔ TRỢ

# Đơn vị hành chính mới và bối cảnh vị trí

**100%**

ghép dữ liệu kinh tế – xã hội (từ 82,5%)

**89,7%**

tin có phường/xã theo đơn vị mới

**11.849**

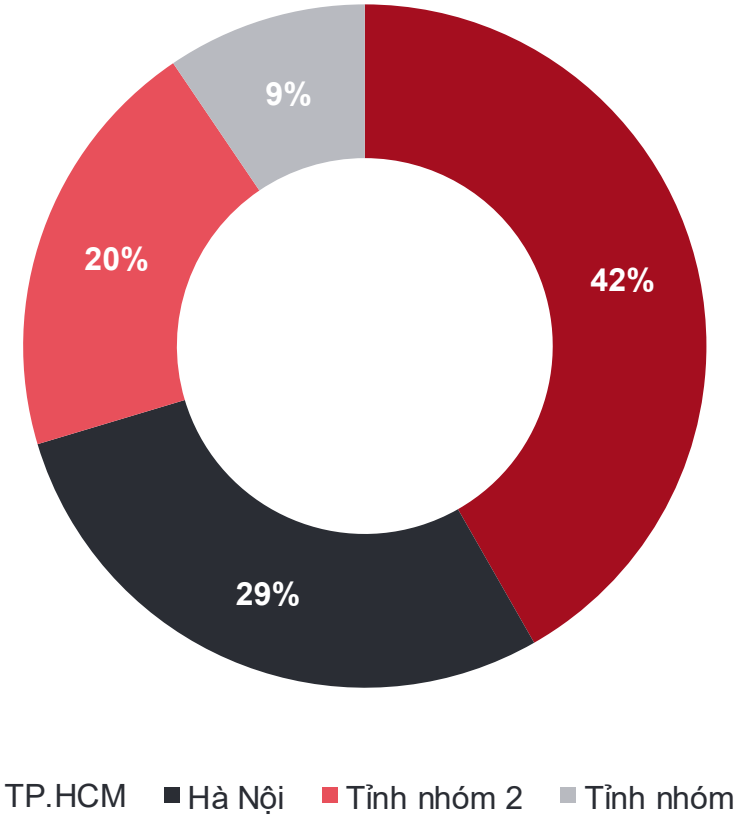
điểm tiện ích: trường, bệnh viện, TTTM, chợ, công viên

**36**

ga metro: Hà Nội 20, TP.HCM 15, Bình Dương 1

- 34 tỉnh mới theo Nghị quyết 202/2025/QH15 dùng để ghép Niên giám thống kê 2025.
- Tên tỉnh, quận cũ được chuẩn hóa và giữ làm feature vị trí chính (tỉnh mới gộp các thị trường giá khác nhau).

15.899 dòng sạch theo vùng thị trường



KIỂM CHỨNG & PHÁT HIỆN VỀ GIÁ

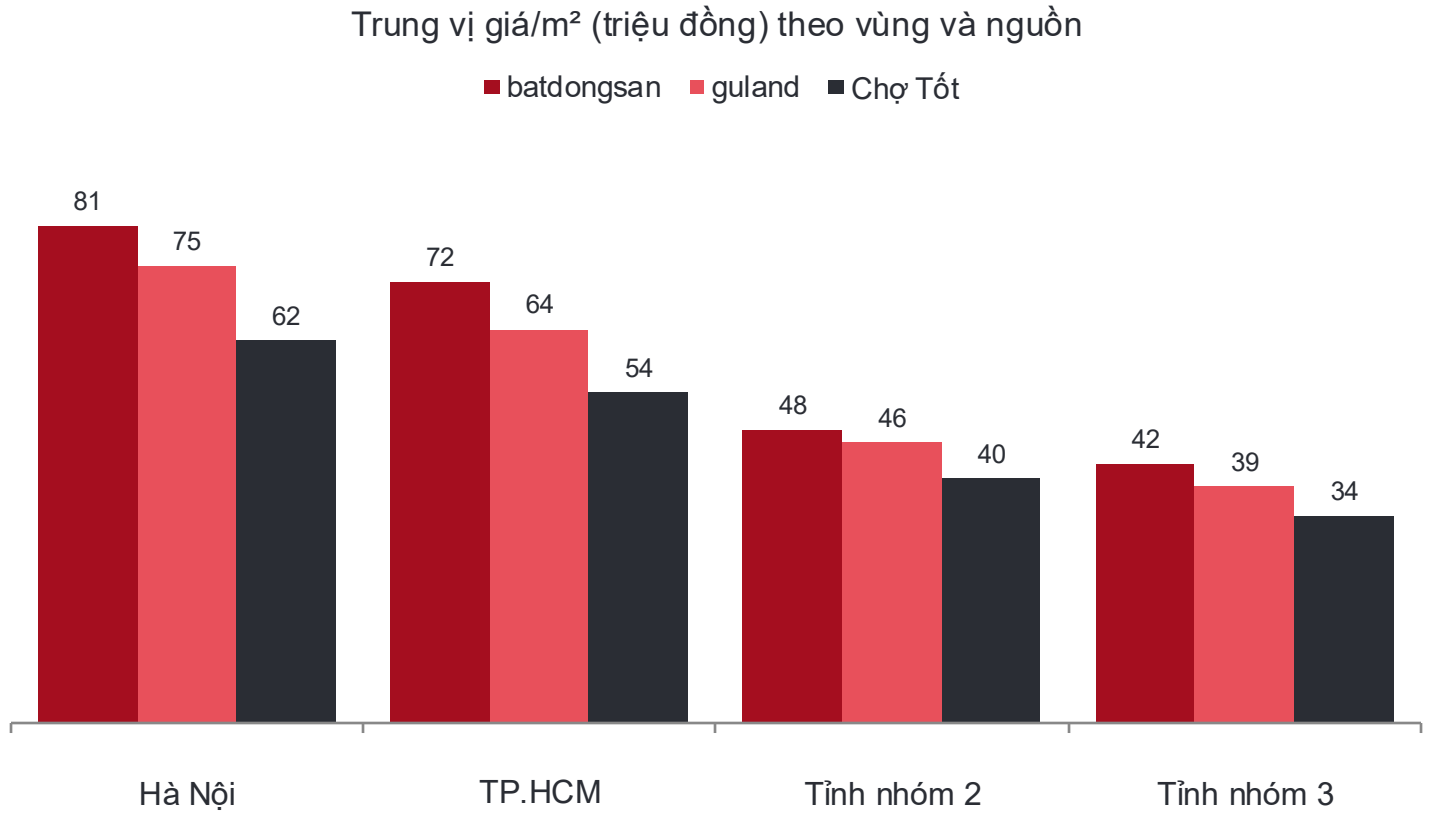
# Dữ liệu chính xác; giá rao chênh lệch giữa các nền tảng

**0 / 12.045**

tin lệch >2% so với giá/m² do chính site hiển thị

**45 / 45**

tin tải lại ngẫu nhiên khớp hoàn toàn với dữ liệu đã lưu




*Cùng một vùng, giá rao trên batdongsan cao hơn Chợ Tốt 20–33%. Nguyên nhân (nền tảng hay thành phần dự án) sẽ được đo trong EDA tuần 4 trước khi quyết định có dùng "nguồn tin" làm feature.*

RỦI RO & HẠN CHẾ

# Các giới hạn đã xác định và cách kiểm soát

### Giá rao, không phải giá giao dịch

Mục tiêu dự đoán là giá chào bán; kết luận phải nêu rõ giới hạn này ngay từ đầu báo cáo.

### Chất lượng guland thấp

39% có tọa độ, 49% có số phòng ngủ. Sẽ đo riêng: mô hình có và không có dữ liệu guland.

### Chênh lệch giá giữa nền tảng

20–33% trong cùng vùng. Báo cáo sai số theo từng nguồn, không chỉ một con số tổng.

### Mất cân bằng vùng

TP.HCM và Hà Nội chiếm 70% dữ liệu sạch. Chia train/test và báo cáo sai số theo từng vùng thị trường.

KẾ HOẠCH TIẾP THEO

# Lộ trình hoàn thành trong tuần 5

## 3 Tuần 3

- Bộ kiểm tra dữ liệu tự động (dừng khi phát hiện lỗi)
- Chia train/test theo nhóm vị trí và nhóm trùng
- Mô hình cơ sở: trung vị giá/m² theo dự án → quận → tỉnh

## 4 Tuần 4

- Phân tích khám phá (EDA) có mục đích
- Tạo feature: căn hộ, vị trí, tiện ích, kinh tế – xã hội
- Huấn luyện mô hình, bảng so sánh từng nhóm feature

## 5 Tuần 5

- Phân tích lỗi trên các dự đoán sai nhiều nhất
- Giải thích mô hình bằng SHAP và shapiq
- Báo cáo cuối và kết luận

*Toàn bộ hạng mục trên là yêu cầu bắt buộc của đề tài. Thời gian dư (nếu có) dành cho các hướng mở rộng ở trang sau.*

HƯỚNG MỞ RỘNG

# Nếu vượt tiến độ: nâng cấp từ mô hình thành sản phẩm

| | | | CÔNG SỨC |
|---|---|---|---|
| 1 | **Khoảng tin cậy cho giá dự đoán** | Quantile regression / conformal prediction: trả về "2,8 – 3,3 tỷ (90%)" thay vì một con số, người dùng biết mức chắc chắn. | Thấp |
| 2 | **Hiệu chỉnh chênh lệch giữa nguồn** | Học độ lệch giá rao batdongsan – Chợ Tốt (20–33%) để quy mọi tin về một thang giá chung. | Thấp |
| 3 | **Phát hiện tin rao bất thường** | Tin có giá lệch mạnh so với dự đoán được gắn nhãn "rẻ / đắt hơn thị trường" — phát hiện tin ảo, tin sai giá. | Thấp |
| 4 | **Khai thác mô tả tin đăng (NLP)** | Trích tầng, view, nội thất, tình trạng pháp lý từ phần mô tả — nguồn thông tin hiện chưa dùng tới. | Trung bình |
| 5 | **Cập nhật dữ liệu định kỳ** | Crawl hàng tuần bằng crawler có sẵn, đóng băng theo phiên bản; theo dõi chỉ số giá theo quận và phát hiện mô hình lỗi thời. | Trung bình |
| 6 | **Demo web định giá căn hộ** | Nhập thông tin căn hộ → giá, khoảng tin cậy và giải thích SHAP các yếu tố làm tăng / giảm giá. | Trung bình |

*Thứ tự ưu tiên: 1–3 tận dụng ngay mô hình và dữ liệu hiện có; 4–6 cần thêm công sức nhưng tăng giá trị ứng dụng thực tế.*